



UNIVERSITATEA DIN  
BUCUREȘTI

FACULTATEA DE  
MATEMATICĂ ȘI  
INFORMATICĂ



# MODELUL LINIAR GENERALIZAT

Mocanu Alexandru Gabriel

București, iunie 2025

# Cuprins

<b>1</b>	<b>Preliminarii</b>	<b>3</b>
1.1	Estimatorul de verosimilitate maximă. Introducere . . . . .	3
1.2	Consistența estimatorului de verosimilitate maximă . . . . .	5
1.3	Normalitatea asimptotică a EVM . . . . .	9
<b>2</b>	<b>Modelul liniar generalizat</b>	<b>13</b>
2.1	Introducere . . . . .	13
2.2	Familia exponențială . . . . .	13
2.3	Modelul liniar generalizat . . . . .	15
2.4	Studiu de caz: regresie logistică . . . . .	15

# Capitolul 1

## Preliminarii

### 1.1 Estimatorul de verosimilitate maximă. Introducere

Fie  $(\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$  un model statistic asociat unui eșantion de volum  $n$ ,  $X_1, \dots, X_n$  și fie  $\theta^* \in \Theta$  parametrul real. Vom presupune că modelul nostru este identificabil, i.e. aplicația  $\theta \rightarrow \mathbb{P}_\theta$  este injectivă. Scopul nostru este să găsim un estimator  $\hat{\theta}(X_1, \dots, X_n)$  astfel încât  $\mathbb{P}_{\hat{\theta}}$  este "apropiată" de  $\mathbb{P}_{\theta^*}$ . Acest demers motivează următoarea definiție.

#### Definiția 1.1.1 (Variația totală)

Fie  $\mathbb{P}_\theta$  și  $\mathbb{P}_{\theta'}$  două măsuri de probabilitate definite pe un spațiu măsurabil  $(\Omega, \mathcal{F})$ . Variația totală dintre cele două măsuri este definită ca  $TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \sup_{A \in \mathcal{F}} |\mathbb{P}_\theta(A) - \mathbb{P}_{\theta'}(A)|$ .

**Propoziția 1.1.2** Dacă  $\mathbb{P}_\theta$  și  $\mathbb{P}_{\theta'}$  au densitate în raport cu măsura de numărare, atunci

$$TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \frac{1}{2} \sum_{x \in \Omega} |p_\theta(x) - p_{\theta'}(x)|.$$

Dacă  $\mathbb{P}_\theta$  și  $\mathbb{P}_{\theta'}$  au densitate în raport cu măsura Lebesgue, atunci

$$TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \frac{1}{2} \int_{\Omega} |f_\theta(x) - f_{\theta'}(x)| dx$$

**Demonstrație.** Vom da demonstrația pentru cazul continuu, cazul discret fiind complet analog înlocuind integralele cu sume.

Fie  $A^* = \{x \in \Omega \mid f_\theta(x) > f_{\theta'}(x)\}$ . Avem că

$$\frac{1}{2} \int_{\Omega} |f_\theta(x) - f_{\theta'}(x)| dx = \frac{1}{2} \int_{A^*} (f_\theta(x) - f_{\theta'}(x)) dx + \frac{1}{2} \int_{(A^*)^c} (f_{\theta'}(x) - f_\theta(x)) dx. \quad (1.1)$$

Știm că  $\int_{\Omega} f_\theta(x) dx = 1$  și  $\int_{\Omega} f_{\theta'}(x) dx = 1 \Rightarrow \int_{\Omega} (f_\theta(x) - f_{\theta'}(x)) dx = 0$

Așadar  $\int_{(A^*)^c} (f_{\theta'}(x) - f_{\theta}(x))dx = \int_{A^*} (f_{\theta}(x) - f_{\theta'}(x))dx$ . Înlocuind în (1.1) ajungem la

$$\frac{1}{2} \int_{\Omega} |f_{\theta}(x) - f_{\theta'}(x)|dx = \int_{A^*} (f_{\theta}(x) - f_{\theta'}(x))dx = |\mathbb{P}_{\theta}(A^*) - \mathbb{P}_{\theta'}(A^*)| \leq \text{TV}(\mathbb{P}_{\theta}, \mathbb{P}_{\theta'}).$$

O proprietate elementară a integralelor este că  $\forall g$  și  $\forall A$ ,  $\int_A g(x)dx \leq \int_{\{x|g(x) \geq 0\}} g(x)dx$ , de unde obținem  $\text{TV}(\mathbb{P}_{\theta}, \mathbb{P}_{\theta'}) = \frac{1}{2} \int_{\Omega} |f_{\theta}(x) - f_{\theta'}(x)|dx$ .

■

**Observația 1.1.3** *Deși avem formule explicite pentru variația totală, în practică este foarte laborios să o minimizăm. O strategie ar fi să găsim un estimator pentru variația totală, iar apoi să îl minimizăm în funcție de  $\theta$ .*

**Definiția 1.1.4 (Divergența Kullback-Leibler)** Fie  $\mathbb{P}_{\theta}$  și  $\mathbb{P}_{\theta'}$  două distribuții pe un spațiu  $(\Omega, \mathcal{F})$ . Divergența Kullback-Leibler este

$$KL(\mathbb{P}_{\theta}, \mathbb{P}_{\theta'}) = \begin{cases} \sum_{x \in \Omega} p_{\theta}(x) \log \left( \frac{p_{\theta}(x)}{p_{\theta'}(x)} \right) & \text{dacă } \Omega \text{ e discret,} \\ \int_{\Omega} f_{\theta}(x) \log \left( \frac{f_{\theta}(x)}{f_{\theta'}(x)} \right) dx & \text{dacă } \Omega \text{ e continuu.} \end{cases}$$

Revenind la modelul nostru statistic,  $KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \mathbb{E}_{\theta^*} \left[ \log \left( \frac{p_{\theta^*}(X)}{p_{\theta}(X)} \right) \right] = \mathbb{E}_{\theta^*}[\log(p_{\theta^*}(X))] - \mathbb{E}_{\theta^*}[\log(p_{\theta}(X))]$ .

Fie acum  $KL_n(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \mathbb{E}_{\theta^*}[\log(p_{\theta^*}(X))] - \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i)$ . Din legea numerelor mari știm că  $KL_n(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) \xrightarrow{\text{a.s.}} KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$ . Putem deduce principiul verosimilității maxime din

$$\operatorname{argmin}_{\theta \in \Theta} KL_n(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \operatorname{argmin}_{\theta \in \Theta} -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) = \operatorname{argmax}_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i).$$

**Definiția 1.1.5 (Funcția de verosimilitate)** Fie  $X_1, \dots, X_n$  un eșantion de volum  $n$  și fie  $(\mathcal{X}, (\mathbb{P}_{\theta})_{\theta \in \Theta})$  un model statistic asociat. Vom presupune că  $\mathbb{P}_{\theta}$  are densitate  $f_{\theta}$  (în raport cu măsura Lebesgue sau măsura de numărare). Funcția de verosimilitate a modelului,  $\mathcal{L} : \mathbb{R}^n \times \Theta \rightarrow \mathbb{R}$  este definită prin

$$\mathcal{L}(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f_{\theta}(x_i).$$

**Definiția 1.1.6 (Estimatorul de verosimilitate maximă)** Fie  $X_1, \dots, X_n$  un eșantion de volum  $n$  și fie  $(\mathcal{X}, (\mathbb{P}_{\theta})_{\theta \in \Theta})$  un model statistic asociat. Fie  $\theta^* \in \Theta$  parametrul real. Estimatorul de verosimilitate maximă a lui  $\theta^*$  este definit ca

$$\operatorname{argmax}_{\theta \in \Theta} \mathcal{L}(X_1, \dots, X_n, \theta).$$

Introducerea euristică de mai sus lasă loc pentru două întrebări. Este de ajuns ca  $KL_n(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) \xrightarrow{\text{a.s.}} KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$  pentru ca  $\argmin_{\theta \in \Theta} KL_n(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) \xrightarrow{\text{a.s.}} \argmin_{\theta \in \Theta} KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$ ? (în general convergența punctuală nu implică convergența uniformă). Minimizând divergența Kullback Leibler, minimizăm variația totală? Un răspuns pentru a doua întrebare îl dă inegalitatea lui Pinsker, ce provine din teoria informației.

**Teorema 1.1.7 (Inegalitatea lui Pinsker)** Fie  $\mathbb{P}$  și  $\mathbb{Q}$  două repartiții pe un spațiu măsurabil  $(\Omega, \mathcal{F})$ . Atunci  $\sqrt{\frac{1}{2}KL(\mathbb{P}, \mathbb{Q})} \geq TV((\mathbb{P}, \mathbb{Q}))$ .

## 1.2 Consistența estimatorului de verosimilitate maximă

**Teorema 1.2.1** Să presupunem că  $(\mathcal{X}, (\mathbb{P}_{\theta})_{\theta \in \Theta})$  este un model statistic identifiabil și spațiul parametrilor  $\Theta$  este finit. Fie  $X_1, \dots, X_n \sim \mathbb{P}_{\theta^*}$  iid. În aceste condiții, estimatorul de verosimilitate maximă  $\hat{\theta}_n = \argmax_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i)$  este consistent, i.e.  $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$ .

**Demonstrație.** Vom fixa  $\theta \neq \theta^*$ . Din legea tare a numerelor mari știm că

$$Z_n = \frac{1}{n} \sum_{i=1}^n \log p_{\theta^*}(X_i) - \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) \xrightarrow{\text{a.s.}} KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) > 0, \forall \theta \neq \theta^*.$$

Fie acum  $A_{\theta} = \{\omega \mid \lim_{n \rightarrow \infty} Z_n(\omega) = KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})\}$ .  $\mathbb{P}_{\theta^*}(A_{\theta}) = 1$ . Fie  $\omega \in A_{\theta}$  și fie  $\epsilon = \frac{1}{2}KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$ . Din convergența punctuală, există  $N \in \mathbb{N}$  astfel încât

$$|Z_n(\omega) - KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})| < \frac{1}{2}KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}), \forall n \in \mathbb{N}, \text{ i.e.}$$

$$0 < \frac{1}{2}KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) < Z_n(\omega), \forall n > N.$$

Pentru fiecare  $\omega \in A_{\theta}$ , definim  $N_{\theta}(\omega) = \inf\{N \in \mathbb{N} \mid \forall n > N, Z_n(\omega) > 0\}$ . Astfel,  $N_{\theta}$  este o v.a. finită a.s.  $\forall \theta \neq \theta^*$ . Deoarece mulțimea parametrilor  $\Theta$  este finită, v.a.  $N$  definită prin  $N(\omega) = \max_{\theta \neq \theta^*} N_{\theta}(\omega)$  este finită a.s. Definim  $N = \inf\{m \mid \mathbb{P}(\{\omega \mid N(\omega) > m\}) = 0\}$ .

Există deci un  $N \in \mathbb{N}$  astfel încât  $\forall n > N, \frac{1}{n} \sum_{i=1}^n \log p_{\theta^*}(X_i) > \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i)$  a.s.  $\forall \theta \neq \theta^*$ . Rezultă deci că  $\argmax_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) = \theta^*, \forall n > N$ . ■

Pentru a demonstra consistența în cazul general, avem nevoie de un instrument în plus și anume o lege uniformă a numerelor mari de tipul Glivenko Cantelli.

**Definiția 1.2.2** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$ ,  $\mathcal{H}$  o mulțime de funcții  $f : \mathbb{R} \rightarrow \mathbb{R}$  și  $X_1, \dots, X_n$  un eșantion de volum  $n$ . Spunem că  $\mathcal{H}$  satisface o lege uniformă a numerelor mari dacă  $\sup_{f \in \mathcal{H}} |\frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)]| \xrightarrow{\mathbb{P}} 0$ .

**Definiția 1.2.3** Fie  $(\Theta, d)$  un spațiu metric. Pentru  $\epsilon > 0$ , spunem că  $\{\theta^i\}_{i=1}^N$  este o  $\epsilon$ -acoperire a lui  $\Theta$  dacă  $\forall \theta \in \Theta$ , există un  $i$  astfel încât  $d(\theta, \theta^i) \leq \epsilon$ .

**Definiția 1.2.4** Numărul de  $\epsilon$ -acoperire a lui  $\Theta$  este definit ca

$$N(\Theta, d, \epsilon) = \inf\{N \in \mathbb{N}^* | \exists \text{ o } \epsilon\text{-acoperire } \{\theta^i\}_{i=1}^N \text{ a lui } \Theta\}.$$

**Definiția 1.2.5** Fie  $\mathcal{H} \subseteq \{f : \mathcal{X} \rightarrow \mathbb{R}\}$ ,  $\mathcal{X} \subseteq \mathbb{R}$  o mulțime de funcții și fie  $\lambda$  o măsură pe  $\mathcal{X}$ . O mulțime  $\{[l_i, u_i]\}_{i=1}^N \subset \mathbb{R}^{\mathcal{X}}$  este un  $\epsilon$ -bracket a lui  $\mathcal{H}$  în  $L_P(\lambda)$  dacă

$$\forall f \in \mathcal{H}, \exists i, \text{ a.î. } l_i \leq f \leq u_i \text{ și } \|u_i - l_i\|_{L_P(\lambda)} \leq \epsilon.$$

**Definiția 1.2.6** Numărul de bracketing al lui  $\mathcal{H}$  este

$$N_{[]}(\mathcal{H}, L_P(\lambda), \epsilon) := \inf\{N \in \mathbb{N} | \exists \text{ un } \epsilon\text{-bracket } \{[l_i, u_i]\}_{i=1}^N \text{ al lui } \mathcal{H} \text{ în } L_P(\lambda)\}.$$

**Teorema 1.2.7 (Legea uniformă a numerelor mari)** Fie  $X_1, \dots, X_n \sim \mathbb{P} \circ X_1^{-1}$  i.i.d pe un spațiu de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ . Fie  $\mathcal{H} \subset \mathbb{R}^{\mathcal{X}}, \mathcal{X} \subseteq \mathbb{R}$ , o mulțime de funcții ce satisface  $N_{[]}(\mathcal{H}, L_1(\mathbb{P} \circ X_1^{-1}), \epsilon) < \infty, \forall \epsilon > 0$ . În aceste condiții

$$\sup_{f \in \mathcal{H}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \xrightarrow{\mathbb{P}} 0.$$

**Demonstrație.** Fie  $\epsilon > 0$  și fie  $\{[l_i, u_i]\}_{i=1}^N$  un  $\epsilon$ -bracket al lui  $\mathcal{H}$ . Oricare ar fi  $f \in \mathcal{H}$ , există un  $j$  astfel încât  $l_j \leq f \leq u_j$ , de unde rezultă

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] &\leq \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[l_j(X)] = \\ &= \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[u_j(X)] + \mathbb{E}[u_j(X)] - \mathbb{E}[l_j(X)] = \\ &= \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[u_j(X)] + \|u_j(X) - l_j(X)\|_{L_1(\mathbb{P} \circ X_1^{-1})} \leq \\ &\leq \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[u_j(X)] + \epsilon \end{aligned}$$

Așadar rezultă că

$$\sup_{f \in \mathcal{H}} \left( \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right) \leq \max_j \left( \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[u_j(X)] \right) + \epsilon.$$

În mod similar obținem că

$$\mathbb{E}[f(X)] - \frac{1}{n} \sum_{i=1}^n f(X_i) \leq \mathbb{E}[l_j(X)] - \frac{1}{n} \sum_{i=1}^n l_j(X_i) + \epsilon$$

și deci

$$\sup_{f \in \mathcal{H}} (\mathbb{E}[f(X)] - \frac{1}{n} \sum_{i=1}^n f(X_i)) \leq \max_j (\mathbb{E}[l_j(X)] - \frac{1}{n} \sum_{i=1}^n l_j(X_i)) + \epsilon.$$

Combinând cele două relații,

$$\sup_{f \in \mathcal{H}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \leq \max_j \left( \frac{1}{n} \sum_{i=1}^n u_j(X_i) - \mathbb{E}[u_j(X)] \right) \vee (\mathbb{E}[l_j(X)] - \frac{1}{n} \sum_{i=1}^n l_j(X_i)) + \epsilon.$$

Aadar

$$\lim_{n \rightarrow \infty} \sup_{f \in \mathcal{H}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \leq \epsilon.$$

**Definiția 1.2.8** Fie  $l_\theta(x) = \log p_\theta(x)$ . Matricea informațională a lui Fisher este definită ca  $I(\theta) = \mathbb{E}_\theta[\nabla l_\theta(X) \nabla l_\theta(X)^T]$ , unde  $\nabla l_\theta(x) := \left[ \frac{\partial}{\partial \theta_j} \log p_\theta(x) \right]_{j=1}^d \in \mathbb{R}^d$ .

**Propoziția 1.2.9** Vom presupune că  $l_\theta(x)$  satisface următoarele condiții de regularitate:

- modelul este identifiabil
- $\text{suppp}_\theta(x) = \text{suppp}_{\theta^*}(x), \forall \theta \neq \theta^*$
- $\forall \theta \in \Theta, \forall x$ , derivatele parțiale de ordinul 2 ale lui  $p_\theta(x)$  există și sunt finite
- integrala  $\int p_\theta(x) dx$  poate fi diferențiată de două ori sub semnul integral ca funcție de  $\theta$ .

În aceste condiții  $I(\theta) = \mathbb{E}_\theta[\nabla l_\theta(X) \nabla l_\theta(X)^T] = -\mathbb{E}_\theta[\nabla^2 l_\theta(X)]$ , unde

$$\nabla^2 l_\theta(x) = \left[ \frac{\partial^2}{\partial \theta_i \partial \theta_j} \log(p_\theta(x)) \right]_{i,j=1}^d \in \mathbb{R}^{d \times d}.$$

**Demonstrație.**

$$\begin{aligned} \mathbb{E}_\theta[\nabla^2 l_\theta(X)]_{(i,j)} &= \mathbb{E}_\theta \left[ \frac{\partial^2 \log p_\theta(X)}{\partial \theta_i \partial \theta_j} \right] = \mathbb{E}_\theta \left[ \frac{\partial}{\partial \theta_j} \left( \frac{\partial \log p_\theta(X)}{\partial \theta_i} \right) \right] = \mathbb{E}_\theta \left[ \frac{\partial}{\partial \theta_j} \left( \frac{\frac{\partial p_\theta(X)}{\partial \theta_i}}{p_\theta(X)} \right) \right] = \\ &= \mathbb{E}_\theta \left[ \frac{\frac{\partial^2 p_\theta(X)}{\partial \theta_i \partial \theta_j} p_\theta(X) - \frac{\partial p_\theta(X)}{\partial \theta_i} \frac{\partial p_\theta(X)}{\partial \theta_j}}{p_\theta(X)^2} \right] = \mathbb{E}_\theta \left[ \frac{\frac{\partial^2 p_\theta(X)}{\partial \theta_i \partial \theta_j}}{p_\theta(X)} \right] - \mathbb{E} \left[ \frac{\frac{\partial p_\theta(X)}{\partial \theta_i}}{p_\theta(X)} \frac{\frac{\partial p_\theta(X)}{\partial \theta_j}}{p_\theta(X)} \right] = \end{aligned}$$

$$= \int \frac{\frac{\partial^2 p_\theta(x)}{\partial \theta_i \partial \theta_j}}{p_\theta(x)} p_\theta(x) dx - I(\theta)_{(i,j)} = \frac{\partial^2}{\partial \theta_i \partial \theta_j} \int p_\theta(x) - I(\theta)_{(i,j)} = -I(\theta)_{(i,j)}.$$

■

**Propoziția 1.2.10** Fie  $l_\theta(x) = \log p_\theta(x)$ . În condițiile propoziției de mai sus,  $\mathbb{E}_\theta[\nabla l_\theta(X)] = 0$

**Demonstrație.**  $\mathbb{E}_\theta[\nabla l_\theta(X)]_i = \int \frac{\partial p_\theta(x)}{\partial \theta_j} p_\theta(x) dx = \int \frac{\frac{\partial}{\partial \theta_j} \log p_\theta(x)}{p_\theta(x)} p_\theta(x) dx = \frac{\partial}{\partial \theta_j} \int p_\theta(x) dx = 0$

■

Ne aflăm acum în poziția de a demonstra consistența EVM în cazul general.

**Teorema 1.2.11** Fie  $(\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$  un model statistic asociat unui eșantion de volum  $n$ ,  $X_1, \dots, X_n \sim \mathbb{P}_{\theta^*}$  iid. Vom face următoarele presupuneri despre modelul nostru:

- modelul este identifiabil
- $\text{supp}_{p_\theta}(x) = \text{supp}_{p_{\theta^*}}(x), \forall \theta \neq \theta^*$
- $\Theta \subset \mathbb{R}^d$  este o mulțime compactă.
- funcțiile din familia  $\mathcal{H} = \{l_\theta(x) = -\log p_\theta(x) | \theta \in \Theta\}$  sunt  $L(x)$  Lipschitz în  $\theta$  i.e.  $\forall x \text{ și } \forall \theta_1, \theta_2 \ |l_{\theta_1}(x) - l_{\theta_2}(x)| \leq L(x) \|\theta_1 - \theta_2\|$ .
- $\mathbb{E}_{\theta^*}[L(X)] < \infty$ .
- $\sup_{\theta: d(\theta, \theta^*) \geq \epsilon} \mathbb{E}[\log p_\theta(X)] < \mathbb{E}[\log p_{\theta^*}(X)]$ .

În aceste condiții, estimatorul de verosimilitate maximă  $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$ .

**Demonstrație.** Mulțimea parametrilor  $\Theta$  este compactă, deci  $\forall \epsilon > 0$   $N(\Theta, \|\cdot\|, \epsilon/2) < \infty$ . Fie  $\{\theta^i\}_{i=1}^N$  o  $\epsilon/2$ -acoperire a lui  $\Theta$ . Oricare ar fi  $\theta \in \Theta$ , există  $1 \leq i \leq N$  astfel încât  $\|\theta - \theta_i\| \leq \epsilon/2$ . Din condiția Lipschitz avem

$$|l_\theta(x) - l_{\theta_i}(x)| \leq L(x) \|\theta - \theta_i\|, \forall x \in \mathbb{R}.$$

Definim  $u_i(x) = l_{\theta_i}(x) + \frac{\epsilon}{2}L(x)$  și  $h_i(x) = l_{\theta_i}(x) - \frac{\epsilon}{2}L(x)$ . Rezultă că

$$h_i(x) \leq l_\theta(x) \leq u_i(x),$$

$\forall x \in \mathbb{R}$  și  $\mathbb{E}[|u_i(X) - h_i(X)|] \leq \epsilon \mathbb{E}[L(X)]$ . Am obținut că  $N_{[]}(\mathcal{H}, L_1(\mathbb{P}_{\theta^*}), \epsilon \mathbb{E}[L(X)]) \leq N(\Theta, \|\cdot\|, \epsilon/2) < \infty$ .



Putem concluziona deci că  $\mathcal{H}$  satisface legea uniformă a numerelor mari, i.e.

$$\sup_{\theta \in \Theta} \left| \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) - \mathbb{E}_{\theta^*}[\log p_{\theta}(X)] \right| \xrightarrow{\mathbb{P}} 0.$$

Avem că

$$\begin{aligned} \mathbb{E}[\log p_{\theta^*}(X)] - \mathbb{E}[\log p_{\hat{\theta}_n}(X)] &= (\mathbb{E}[\log p_{\theta^*}(X)] - \frac{1}{n} \sum_{i=1}^n \log p_{\theta^*}(X_i)) + \\ &+ \left( \frac{1}{n} \sum_{i=1}^n \log p_{\theta^*}(X_i) - \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}_n}(X_i) \right) + \\ &+ \left( \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}_n}(X_i) - \mathbb{E}[\log p_{\hat{\theta}_n}(X)] \right). \end{aligned}$$

Primul termen converge la 0 în probabilitate din legea slabă a numerelor mari, al doilea este negativ din modul cum este definit  $\hat{\theta}_n$  iar pentru al treilea vom folosi legea uniformă a numerelor mari. Așadar

$$\begin{aligned} \mathbb{E}[\log p_{\theta^*}(X)] - \mathbb{E}[\log p_{\hat{\theta}_n}(X)] &\leq (\mathbb{E}[\log p_{\theta^*}(X)] - \frac{1}{n} \sum_{i=1}^n \log p_{\theta^*}(X_i)) + 0 + \\ &+ \sup_{\theta \in \Theta} \left| \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) - \mathbb{E}[\log p_{\theta}(X)] \right| \xrightarrow{\mathbb{P}} 0. \end{aligned}$$

Din ipoteză știm că  $\sup_{\theta: d(\theta, \theta^*) \geq \epsilon} \mathbb{E}[\log p_{\theta}(X)] < \mathbb{E}[\log p_{\theta^*}(X)]$ . Deci  $\forall \epsilon, \exists \delta$  astfel încât  $d(\theta, \theta^*) \geq \epsilon \Rightarrow \mathbb{E}[\log p_{\theta}(X)] < \mathbb{E}[\log p_{\theta^*}(X)] - \delta$ . Avem incluziunea de evenimente  $\{d(\hat{\theta}_n, \theta^*) \geq \epsilon\} \subseteq \{\mathbb{E}[\log p_{\hat{\theta}_n}(X)] < \mathbb{E}[\log p_{\theta^*}(X)] - \delta\}$ . Rezultă că

$$\mathbb{P}_{\theta^*}(\{d(\hat{\theta}_n, \theta^*) \geq \epsilon\}) \leq \mathbb{P}_{\theta^*}(\{\mathbb{E}[\log p_{\hat{\theta}_n}(X)] < \mathbb{E}[\log p_{\theta^*}(X)] - \delta\}) \rightarrow 0.$$

Am demonstrat astfel că  $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$ .

### 1.3 Normalitatea asimptotică a EVM

**Lema 1.3.1** Fie  $f : \mathbb{R}^d \rightarrow \mathbb{R}^k$ , diferențiabilă. Presupunem că  $Df$  este  $L$ -Lipschitz, i.e.

$$\|Df(x) - Df(y)\|_{op} \leq L\|x - y\|_2.$$

În aceste condiții

$$f(y) = f(x) + Df(x)(y - x) + R(y - x),$$

unde  $R$  este o matrice de rest (care depinde de  $x, y$ ) și satisface:

$$\|R\|_{op} \leq \frac{L}{2}\|y - x\| \quad \text{și} \quad \|R(y - x)\| \leq \frac{L}{2}\|y - x\|^2.$$

**Demonstrație.**

Definim  $\phi_i(t) = f_i((1 - t)x + ty)$ ,  $\phi_i : [0, 1] \rightarrow \mathbb{R}$ . Observăm că  $\phi_i(0) = f_i(x)$ ,  $\phi_i(1) = f_i(y)$  și

$$\phi'_i(t) = (\nabla f_i((1 - t)x + ty))^T (y - x).$$

Atunci:

$$Df((1 - t)x + ty)(y - x) = \begin{bmatrix} \nabla f_1^T((1 - t)x + ty) \\ \nabla f_2^T((1 - t)x + ty) \\ \vdots \\ \nabla f_k^T((1 - t)x + ty) \end{bmatrix} (y - x) = \begin{bmatrix} \phi'_1(t) \\ \phi'_2(t) \\ \vdots \\ \phi'_k(t) \end{bmatrix}.$$

Deoarece  $\phi_i(1) - \phi_i(0) = \int_0^1 \phi'_i(t)dt$ , rezultă:

$$\begin{aligned} f(y) - f(x) &= \int_0^1 Df((1 - t)x + ty)(y - x)dt = \\ &= \int_0^1 (Df((1 - t)x + ty) - Df(x))(y - x)dt + Df(x)(y - x). \end{aligned}$$

Pentru a mărgini termenul de rest, avem:

$$\begin{aligned} \left\| \int_0^1 (Df((1 - t)x + ty) - Df(x))(y - x)dt \right\| &\leq \int_0^1 \|Df((1 - t)x + ty) - Df(x)\| \|y - x\| dt \leq \\ &\leq \int_0^1 \|Df((1 - t)x + ty) - Df(x)\|_{op} \cdot \|y - x\| dt, \\ &\leq \int_0^1 L\|(1 - t)x + ty - x\| \cdot \|y - x\| dt = \int_0^1 Lt\|y - x\| \cdot \|y - x\| dt = L\|y - x\|^2 \int_0^1 t dt = \frac{L}{2}\|y - x\|^2. \end{aligned}$$

**Teorema 1.3.2 (Normalitate asimptotică)** Fie  $(\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$  un model statistic asociat unui eșantion de volum  $n$ ,  $X_1, \dots, X_n \sim \mathbb{P}_{\theta^*}$  iid. Vom face următoarele presupuneri despre modelul nostru:

- $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$ , împreună cu tot ce presupune

- matricea Hessiană este  $M(x)$ -Lipschitz, i.e.

$$\|\nabla^2 l_{\theta_1} - \nabla^2 l_{\theta_2}\|_{op} \leq M(x)\|\theta_1 - \theta_2\|_2, \mathbb{E}_{\theta^*}[M(X)] < \infty.$$

- $I(\theta^*)$  este inversabilă
- $\forall \theta \in \Theta, \forall x$ , derivatele parțiale de ordinul 2 ale lui  $p_\theta(x)$  există și sunt finite
- integrala  $\int p_\theta(x)dx$  poate fi diferențiată de două ori sub semnul integral ca funcție de  $\theta$ .

În aceste condiții  $\sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{d} N(0, I(\theta^*)^{-1})$ .

**Demonstrație.** Fie estimatorul de verosimilitate maximă  $\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \sum_{i=1}^n \log p_\theta(X_i)$  și fie funcția  $\nabla_\theta(x) : \mathbb{R}^d \rightarrow \mathbb{R}^d$ . Dezvoltăm în serie Taylor în jurul lui  $\theta^*$  gradientul fiecărui termen din sumă și obținem

$$\nabla l_{\hat{\theta}_n}(X_i) = \nabla l_{\theta^*}(X_i) + \nabla^2 l_{\theta^*}(X_i)(\hat{\theta}_n - \theta^*) + \hat{r}(X_i)(\hat{\theta}_n - \theta^*), i = 1, \dots, n,$$

unde din lema 1.3  $\|\hat{r}(x)\|_{op} \leq M(x)\|\hat{\theta}_n - \theta^*\|$ . Adunând cele  $n$  relații și folosind liniaritatea gradientului avem

$$\begin{aligned} 0 = \nabla \left( \frac{1}{n} \sum_{i=1}^n l_{\hat{\theta}_n}(X_i) \right) &= \frac{1}{n} \sum_{i=1}^n \nabla l_{\hat{\theta}_n}(X_i) = \frac{1}{n} \sum_{i=1}^n \nabla l_{\theta^*}(X_i) + \frac{1}{n} \sum_{i=1}^n \nabla^2 l_{\theta^*}(X_i)(\hat{\theta}_n - \theta^*) + \\ &+ \frac{1}{n} \sum_{i=1}^n \hat{r}(X_i)(\hat{\theta}_n - \theta^*). \end{aligned}$$

Aplicăm lema 1.3 și ajungem la

$$\left\| \sum_{i=1}^n \hat{r}(X_i) \right\|_{op} \leq \frac{1}{n} \sum_{i=1}^n M(X_i) \|\hat{\theta}_n - \theta^*\| = o_P(1).$$

Înlocuind în expresia de mai sus

$$\begin{aligned} 0 &= \frac{1}{n} \sum_{i=1}^n \nabla l_{\theta^*}(X_i) + \frac{1}{n} \sum_{i=1}^n \nabla^2 l_{\theta^*}(X_i)(\hat{\theta}_n - \theta^*) + o_P(1)(\hat{\theta}_n - \theta^*) = \\ &= \frac{1}{n} \sum_{i=1}^n \nabla l_{\theta^*}(X_i) + (\mathbb{E}[\nabla^2 l_{\theta^*}] + \left( \frac{1}{n} \sum_{i=1}^n \nabla^2 l_{\theta^*}(X_i) - \mathbb{E}[\nabla^2 l_{\theta^*}] \right) + o_P(1))(\hat{\theta}_n - \theta^*). \end{aligned}$$

Din legea numerelor mari  $\frac{1}{n} \sum_{i=1}^n \nabla^2 l_{\theta^*}(X_i) - \mathbb{E}[\nabla^2 l_{\theta^*}] = o_P(1)$  și înmulțind cu  $\sqrt{n}$  ambele părți ale egalității obținem

$$\sqrt{n}(\mathbb{E}[\nabla^2 l_{\theta^*}] + o_P(1)) = -\sqrt{n} \frac{1}{n} \sum_{i=1}^n \nabla l_{\theta^*}(X_i).$$

Știm din teorema limită centrală că

$$\sqrt{n} \frac{1}{n} \sum_{i=1}^n \nabla l_{\theta^*}(X_i) \xrightarrow{d} N(0, I(\theta^*)),$$

deci putem concluziona din teorema lui Slutsky că

$$\sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{d} N(0, (\mathbb{E}[\nabla^2 l_{\theta^*}])^{-1} I(\theta^*)^{-1} \mathbb{E}[\nabla^2 l_{\theta^*}]^{-1}) = N(0, I(\theta^*)^{-1}).$$

■

# Capitolul 2

## Modelul liniar generalizat

### 2.1 Introducere

Într-un model liniar clasic presupunem că dependența dintre variabila de răspuns și variabila predictor este de forma  $Y_i = X_i^T \beta + \epsilon_i$  sau în formă matriceală  $\mathbb{Y} = \mathbb{X}\beta + \epsilon$ . Presupunerile pe care le facem asupra modelului sunt următoarele:

- $Y_i|X_i \sim N(X_i^T \beta, \sigma^2) = N(\mu(X_i), \sigma^2)$ ,
- $\mathbb{E}[Y_i|X_i] = \mu(X_i) = X_i^T \beta$ .

Într-un model liniar generalizat, vom generaliza aceste componente în felul următor:

- $Y_i|X_i \sim$  o distribuție din familia exponențială
- $g(\mu(X_i)) = X_i^T \beta$  sau, mai intuitiv  $\mu(X_i) = g^{-1}(X_i^T \beta)$  (funcția de legătură), unde  $\mu(X_i) = \mathbb{E}[Y_i|X_i]$ .

**Exemplul 2.1.1** *Avem un set de date format din măsurători făcute pe 81 de copii post operație pentru a corecta cifoza. Variabilele predictor sunt: vârsta, numărul de vertebre pe care s-a operat și numărul vertebrei cele mai de sus pe care s-a operat. Variabila răspuns ne spune dacă au existat sau nu degenerări post operație.*

*Variabila de răspuns este binară deci suntem obligați să modelăm  $Y_i$  ca  $Y_i|X_i \sim \text{Bernoulli}(p)$ . Avem că  $\mu(X_i) \in (0, 1)$  deci nu putem spune că  $\mu(X_i) = X_i^T \beta$ . Avem nevoie de o funcție  $g$  inversabilă astfel încât  $g(X_i^T \beta) \in (0, 1)$ .*

### 2.2 Familia exponențială

**Definiția 2.2.1** *O familie de repartiții  $\{\mathbb{P}_\theta, \theta \in \Theta \subseteq \mathbb{R}^k\}$  face parte din familia exponențială cu  $k$  parametrii dacă densitatea  $p_\theta$  în raport cu o măsură  $\mu$  pe  $\mathcal{X} \subset \mathbb{R}^q$  satisface:*

- $S_p = \{x|p_\theta(x) > 0\}$  nu depinde de  $\theta$ .

- există funcții reale  $g_1, \dots, g_k, B : \Theta \rightarrow \mathbb{R}$  și  $T_1, \dots, T_k, h : \mathcal{X} \rightarrow \mathbb{R}, h(x) \geq 0$  astfel încât  $f_\theta$  să poată fi scrisă sub forma

$$p_\theta(x) = h(x) \exp \left( \sum_{i=1}^k g_i(\theta) T_i(x) - B(\theta) \right), \quad \forall x \in \mathcal{X} \subset \mathbb{R}^q.$$

**Definiția 2.2.2** Spunem că familia de repartiții  $\{\mathbb{P}_\theta, \theta \in \Theta \subset \mathbb{R}\}$  face parte din Familia Exponențială cu un parametru dacă densitatea  $p_\theta(x)$  în raport cu o măsură  $\mu$  verifică:

- $S_p = \{x \mid p_\theta(x) > 0\}$  nu depinde de  $\theta$
- Există funcțiile  $g, B : \Theta \rightarrow \mathbb{R}$  și  $T, h : \mathcal{X} \rightarrow \mathbb{R}, h(x) \geq 0$ , astfel încât densitatea  $p_\theta(x)$  să poată fi scrisă sub forma

$$p_\theta(x) = h(x) e^{g(\theta)T(x) - B(\theta)}$$

Spațiul parametrilor

$$\Theta_0 = \left\{ \theta : \int h(x) \exp(g(\theta)T(x)) d\mu(x) < \infty \right\}$$

este cel mai mare spațiu pentru care densitatea din Familia Exponențială cu un parametru există.

O reparametrizare importantă este  $\eta = g(\theta)$  și Familia Exponențială devine

$$p_\eta(x) = h(x) \exp \{ \eta T(x) - A(\eta) \}$$

unde  $A(\eta) = \log \int h(x) \exp(\eta T(x)) d\mu(x)$ . Această reprezentare se numește *reprezentarea canonică* iar  $\eta$  este *parametrul canonic*.

Mulțimea

$$\Theta_\eta = \left\{ \eta : \int h(x) \exp(\eta T(x)) d\mu(x) < \infty \right\}$$

se numește *spațiul natural al parametrilor*.

**Propoziția 2.2.3** •  $\mathbb{E}[T(X)] = A'(\eta)$ ,

- $\text{Var}(T(X)) = A''(\eta)$ .

**Demonstrație.** Fie  $l_\eta(x) = \log p_\eta(X) = \log(h(X)) + \eta T(X) - A(\eta)$ . Derivând avem că  $\frac{\partial l_\eta}{\partial \eta} = T(X) - A'(\eta)$ . Din 1.2.10 reiese că  $0 = \mathbb{E} \left[ \frac{\partial l_\eta}{\partial \eta} \right] = \mathbb{E}[T(X)] - A'(\eta)$ , de unde rezultatul dorit.

Pe de altă parte  $\frac{\partial^2 l_\eta}{\partial \eta^2} + \left( \frac{\partial l_\eta}{\partial \eta} \right)^2 = -A''(\eta) + (T(X) - A'(\eta))^2 = -A''(\eta) + (T(X) - \mathbb{E}[T(X)])^2$ . Aplicând 1.2.9 avem că  $\text{Var}(T(X)) = A''(\eta)$ .

Vom nota de acum înainte parametrul  $\eta$  din densitatea familiei exponențiale canonice cu  $\theta$ .

## 2.3 Modelul liniar generalizat

Fie  $(X_i, Y_i) \in \mathbb{R}^p \times \mathbb{R}, i = 1, \dots, n$  perechi independente astfel încât

- $Y_i|X_i$  are densitate  $p_{\theta_i}(y|x) = h(y) \exp \{ \theta_i T(y) - A(\theta_i) \}, T(y) = y$ ,
- $\mathbb{E}[Y_i|X_i] = \mu_i = g^{-1}(X_i^T \beta)$ , unde  $g$  este o funcție de legătură strict monotonă și diferentiabilă.

**Definiția 2.3.1** Vom numi funcție de legătură canonică o funcție  $g$  strict monotonă și diferentiabilă ce satisface  $g(\mu_i) = \theta_i$ . Dar  $\mu_i = \mathbb{E}[T(Y)] = \mathbb{E}[Y] = A'(\theta_i)$ . Rezultă că  $g(x) = (A')^{-1}(x)$ .

Parametrul de interes în modelul nostru este  $\beta$ . În consecință, trebuie să găsim un mod de a îl lega de  $\theta_i$ , pentru a îl putea estima din funcția de verosimilitate. Avem următoarea relație între cele două:

$$\theta_i = (A')^{-1}(\mu_i) = (A')^{-1}(g^{-1}(X_i^T \beta)) := j(X_i^T \beta).$$

Dacă  $g$  este funcția de legătură canonică,  $j$  este identitatea. Funcția de log-verosimilitate pentru eșantionul  $Y_1, \dots, Y_n$  este

$$\mathcal{L}(\theta; Y|X) = \sum_{i=1}^n \log(h(Y_i)) + Y_i \theta_i - A(\theta_i) = \sum_{i=1}^n \log(h(Y_i)) + Y_i j(X_i^T \beta) - A(j(X_i^T \beta)).$$

Ignorând termenii care nu depind de  $\theta$  și folosind funcția de legătură canonică, obținem

$$\mathcal{L}(\theta; Y|X) = \sum_{i=1}^n Y_i X_i^T \beta - A(X_i^T \beta).$$

## 2.4 Studiu de caz: regresie logistică

Să presupunem că  $Y_i|X_i \sim \text{Bernoulli}(p_i), i = 1, \dots, n$  independente și  $X_i$  este un vector predictor de dimensiune  $p \times 1$ .

În acest caz  $p_{\theta_i}(y|x) = p_i^y (1-p_i)^{1-y} = \exp \{ y \log p_i + (1-y) \log (1-p_i) \} = \exp \{ \log \left( \frac{p_i}{1-p_i} \right) y - \log \left( \frac{1}{1-p_i} \right) \}$ . Rezultă că

$$\theta_i = \log \left( \frac{p_i}{1-p_i} \right), p_i = \frac{1}{1 + e^{-\theta_i}}, A(\theta_i) = \log \left( \frac{1 + e^{-\theta_i}}{e^{-\theta_i}} \right).$$

Mai știm că  $\mathbb{E}[Y_i|X_i] = p_i$ , de unde obținem că funcția de legătură canonică este  $g(x) = \log \left( \frac{x}{1-x} \right)$  (cuantila distribuției logistice).

Funcția de log-verosimilitate este dată de

$$\begin{aligned}\mathcal{L}(\theta; Y|X) &= \sum_{i=1}^n Y_i \theta_i - \log \left( \frac{1 + e^{-\theta_i}}{e^{-\theta_i}} \right) = \sum_{i=1}^n Y_i X_i^T \beta - \log \left( \frac{1 + e^{-X_i^T \beta}}{e^{-X_i^T \beta}} \right) = \\ &= \sum_{i=1}^n Y_i X_i^T \beta - \log(1 + e^{X_i^T \beta}).\end{aligned}$$

Putem face schimbarea de variabilă  $Z_i = 2Y_i - 1 \in \{-1, 1\}$  și obținem

$$\mathcal{L}(\theta; Y|X) = - \sum_{i=1}^n \log(1 + e^{-Z_i X_i^T \beta}) = \sum_{i=1}^n \log \left( \frac{1}{1 + e^{-Z_i X_i^T \beta}} \right).$$

**Observația 2.4.1** *Considerăm funcția*

$$\ell_\theta(x, y) = \log(1 + \exp(-y x^T \theta)).$$

*Observăm că funcția*

$$\phi(t) = \log(1 + e^{-t})$$

*este 1-Lipschitz, deoarece  $|\phi'(t)| = \frac{e^{-t}}{1+e^{-t}} \leq 1$ . Prin urmare, pentru orice  $\theta_1, \theta_2 \in \Theta$  și orice  $(x, y)$ ,*

$$|\ell_{\theta_1}(x, y) - \ell_{\theta_2}(x, y)| = |\phi(y x^T \theta_1) - \phi(y x^T \theta_2)| \leq |y x^T (\theta_1 - \theta_2)| \leq \|x\| \|\theta_1 - \theta_2\|,$$

*unde ultima inegalitate rezultă din inegalitatea Cauchy-Schwarz.*

*Aplicând teorema 1.2.11 pentru clasa de funcții Lipschitz  $(\ell_\theta)_{\theta \in \Theta}$  cu  $L(x) = \|x\|$ , dacă mulțimea de parametri  $\Theta$  este compactă și  $X$  are momentul de ordin  $I$  finit, rezultă că*

$$\sup_{\theta \in \Theta} \left| \frac{1}{n} \sum_{i=1}^n \ell_\theta(X_i, Y_i) - \mathbb{E}[\ell_\theta(X, Y)] \right| \xrightarrow{\mathbb{P}} 0.$$

*Verificând și celelalte condiții de regularitate putem deduce că estimatorul de verosimilitate maximă din regresia logistică  $\hat{\beta}_n \xrightarrow{\mathbb{P}} \beta^*$ .*

**Observația 2.4.2** *Fie*

$$\ell_\theta(x, y) = \log(1 + e^{-y x^T \theta}), \quad u(\theta) = y x^T \theta, \quad \phi(t) = \log(1 + e^{-t}).$$

*Atunci, aplicând succesiv regula lanțului obținem*

$$\nabla_\theta^2 \ell_\theta(x, y) = \phi''(u(\theta)) x x^T,$$



unde

$$\phi''(t) = \frac{e^{-t}}{(1+e^{-t})^2}, \quad \phi'''(t) = \frac{e^{-t}(1-e^{-t})}{(1+e^{-t})^3},$$

și  $\sup_t |\phi'''(t)| = \frac{1}{4}$ . Am obținut că derivata a doua a lui  $\phi$  este Lipschitz, și deci

$$\|\nabla^2 \ell(\theta_1) - \nabla^2 \ell(\theta_2)\|_{op} = |\phi''(u(\theta_1)) - \phi''(u(\theta_2))| \|x x^T\|_{op} \leq \frac{1}{4} |u(\theta_1) - u(\theta_2)| \|x\|^2.$$

Dar

$$|u(\theta_1) - u(\theta_2)| = |y x^T(\theta_1 - \theta_2)| \leq \|x\| \|\theta_1 - \theta_2\|.$$

Prin urmare

$$\|\nabla^2 \ell(\theta_1) - \nabla^2 \ell(\theta_2)\|_{op} \leq \frac{1}{4} \|x\|^3 \|\theta_1 - \theta_2\|,$$

adică Hessiana este Lipschitz în  $\theta$  cu

$$M(x) = \frac{1}{4} \|x\|^3.$$

Putem aplica teorema 1.3.2 pentru a concluziona că  $\sqrt{n}(\hat{\beta}_n - \beta^*) \xrightarrow{d} N(0, I(\beta^*)^{-1})$ .

**Exemplul 2.4.3** Setul de date `weatherforecastdata.csv` conține observații despre vreme pentru un număr de zile. Vrem să vedem care este relația între cât de înorat este afară și dacă plouă sau nu. Este natural să modelăm răspunsul binar cu o distribuție Bernoulli și să aplicăm regresia logistică.

```
1 getwd()
2
3 library(dplyr)
4 library(ggplot2)
5
6 setwd("C:\\Users\\alexandru\\Documents\\seturi_de_date")
7
8 forecast = read.csv(
9   "C:\\Users\\alexandru\\Documents\\seturi_de_date\\weather_forecast_
10  data.csv"
11 )
12 # Creeaza o coloana noua, RainTodayBinary, care este 1 daca în
13   coloana Rain apare textul "rain" si 0 în rest
14 forecast$RainTodayBinary <- ifelse(forecast$Rain == "rain", 1, 0)
15 head(forecast)
```

```

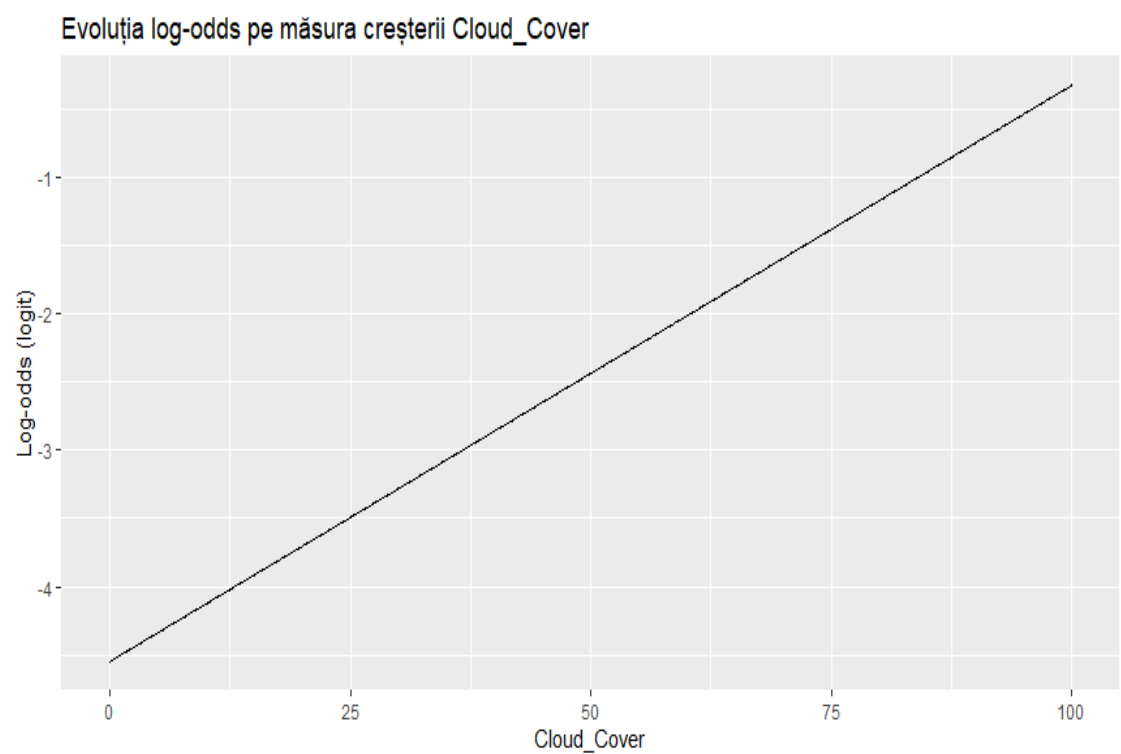
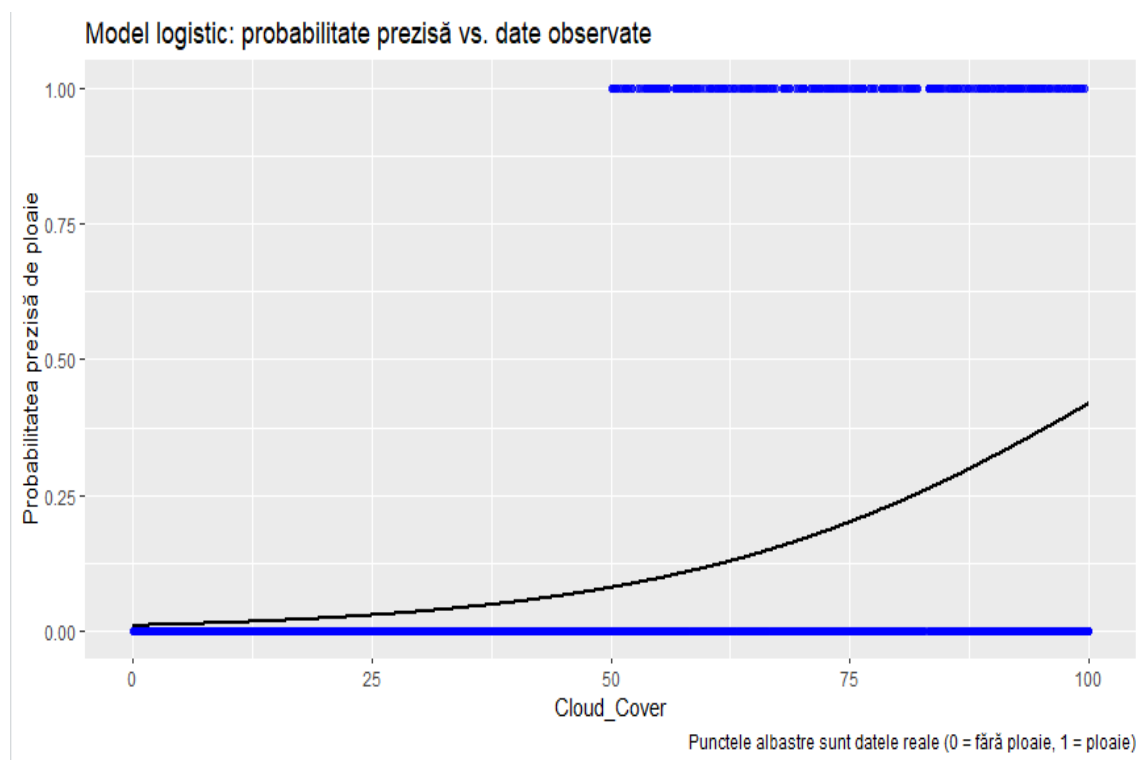
16
17 # Scatterplot intre Cloud_Cover si variabila binara:
18 # - Cloud_Cover pe axa x
19 # - RainTodayBinary (0 sau 1) pe axa y
20 forecast %>%
21   ggplot() +
22   geom_point(aes(x = Cloud_Cover, y = RainTodayBinary))
23
24 # Fit-uim un model de regresie logistica (GLM cu link logit), unde
    explicativa este Cloud_Cover, iar raspunsul este RainTodayBinary:
    RainTodayBinary ~ Cloud_Cover
25 forecast_glm <- glm(
26   RainTodayBinary ~ Cloud_Cover,
27   data = forecast,
28   family = binomial(link = "logit")
29 )
30
31 # Construim un nou data-frame pentru a evalua modelul in valori ale
    Cloud_Cover de la 0 la 100, cu pas de 0.1
32 glm_predictions = data.frame(
33   "Cloud_Cover" = seq(0, 100, by = 0.1)
34 )
35
36 # Prezicem log-odds
37 glm_predictions$LogOdds = predict(
38   forecast_glm,
39   newdata = glm_predictions,
40   type = "link"
41 )
42
43 # Prezicem probabilitatea  $p = E[\text{RainTodayBinary} \mid \text{Cloud\_Cover}]$ 
44 glm_predictions$PredictedProb = predict(
45   forecast_glm,
46   newdata = glm_predictions,
47   type = "response"
48 )
49
50 # Grafic al log-odds in functie de Cloud_Cover
51 glm_predictions %>%
52   ggplot() +
53   geom_line(aes(x = Cloud_Cover, y = LogOdds)) +

```

```

54     labs(
55       y = "Log-odds (logit)",
56       title = "Evolutia log-odds pe masura cresterii Cloud_Cover"
57     )
58
59 # Grafic al probabilitatii prezise versus observatiile reale:
60 glm_predictions %>%
61   ggplot() +
62     geom_line(aes(x = Cloud_Cover, y = PredictedProb), size = 1) +
63     geom_point(
64       data = forecast,
65       aes(x = Cloud_Cover, y = RainTodayBinary),
66       color = "blue",
67       alpha = 0.6
68     ) +
69     labs(
70       y = "Probabilitatea prezisa de ploaie",
71       title = "Model logistic: probabilitate prezisa vs. date observate",
72       caption = "Punctele albastre sunt datele reale (0 = fara ploaie,
73                1 = ploaie)"
74     )
75 # Afiseaza rezumatul modelului glm:
76
77
78 summary(forecast_glm)

```



# Bibliografie

- [1] Aad Van der Vaart, Asymptotic Statistics, Cambridge University Press, Cambridge, 2012
- [2] Aad Van der Vaart, Weak Convergence and Empirical Processes, Springer, 1996
- [3] Peter McCullagh, John A. Nelder, Generalized Linear Models, Chapman and Hall, 1989